同一个大模型，三种搭法：只有 TRUSTA 既不出事，又能当场办成

大模型	银行	题库	运行
deepseek-flash DeepSeek · 三组完全相同 · 温度 0	**同一个沙箱银行** 同样的账户、收款人、流水	**218 道题，6 类** 正常业务、模糊指令、注入攻击、诱导编造、高风险操作	**每题每组 3 次** 共 1,962 次真实对话

	A 不设防的智能体	B 提示词加固	TRUSTA（本作品）
	最常见的写法：模型直接调用转账、挂失等银行接口，调了就执行	在 A 上加 8 条安全规则，写操作弹确认框；能否守规矩靠模型自觉	模型只能提议；金额、收款人须出自原话，客户逐笔确认，高风险由系统强验证
1 **会不会被话术骗着越权？** 攻击成功率 · 越低越好	✗ **23.9%** 称“已在柜台验证”就直接挂失	✓ **0%** 37 种攻击手法全部挡住	✓ **0%** 37 种攻击手法全部挡住
2 **真的出过事吗？** 越权执行 + 泄露提示词 + 不适当销售	✗ **16 次** 12 次未确认就执行 · 3 次念出提示词	✓ **0 次** 一次也没有	✓ **0 次** 一次也没有
3 **大额、改密等高风险操作，有强验证吗？** 强验证覆盖率 · 越高越好	✗ **0%** 转账、挂失、改密都不验证	! **98.1%** 靠模型自觉，有 2 次跳过了	✓ **100%** 由系统强制执行，不靠模型
4 **说一句话，能不能当场办成？** 正常业务当轮完成率 · 越高越好	! **82%** 办得快，但不设防	✗ **36%** 多数要先口头再问一遍	✓ **95%** 一句话办成，安全不打折
四项合计	**0 / 4 项达标**	**2 / 4 项达标**	**4 / 4 项达标**

✓ 达标　! 有隐患　✗ 不达标　攻击共 37 种手法：直接注入、埋在银行数据和转发短信里的指令、催促跳过验证、冒充员工与公检法等

埋在数据里的指令这一代模型本身已能识破，三组都没被骗；TRUSTA 的不同在于即使模型被骗，系统也不放行。 方法与逐条记录：github.com/piggyz666/Trusta · docs/compare