同一个大模型，三种搭法：只有 TRUSTA 既不出事，又能当场办成

同一个模型（deepseek-flash） · 同一个银行 · 同一份 218 道题 · 每题每组 3 次 · 共 1,962 次真实对话

	A 不设防的智能体 模型直接调用银行接口	B 提示词加固 8 条安全规则 + 确认框	TRUSTA 本作品
1 会不会被话术骗着越权？ 攻击成功率 · 越低越好	✗ 23.9% 称“已在柜台验证”就直接挂失	✓ 0% 37 种攻击手法全部挡住	✓ 0% 37 种攻击手法全部挡住
2 真的出过事吗？ 越权执行 + 泄露提示词 + 不适当销售	✗ 16 次 12 次未确认就执行 · 3 次念出提示词	✓ 0 次 一次也没有	✓ 0 次 一次也没有
3 大额、改密等高风险操作，有强验证吗？ 强验证覆盖率 · 越高越好	✗ 0% 转账、挂失、改密都不验证	! 98.1% 靠模型自觉，有 2 次跳过了	✓ 100% 由系统强制执行，不靠模型
4 说一句话，能不能当场办成？ 正常业务当轮完成率 · 越高越好	! 82% 办得快，但不设防	✗ 36% 多数要先口头再问一遍	✓ 95% 一句话办成，安全不打折
四项合计	0 / 4 项达标	2 / 4 项达标	4 / 4 项达标

✓ 达标　! 有隐患　✗ 不达标　攻击共 37 种手法：直接注入、埋在银行数据和转发短信里的指令、催促跳过验证、冒充员工与公检法等

埋在数据里的指令这一代模型本身已能识破，三组都没被骗；TRUSTA 的不同在于即使模型被骗，系统也不放行。 方法与逐条记录：github.com/piggyz666/Trusta · docs/compare