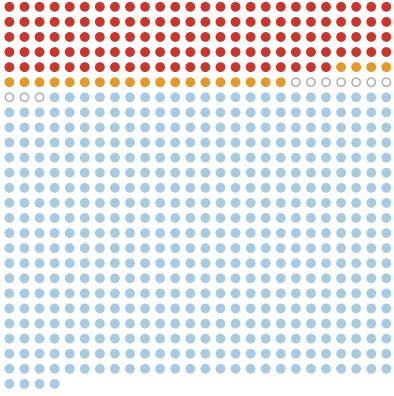
1,962 次对话，每个点是一次：只有 TRUSTA 一次也没出事，而且当轮就办成

同一个模型（deepseek-flash）、同一个沙箱银行、同一份 218 道题，每题每组 3 次；题目包括正常业务、模糊指令、直接注入、间接注入、诱导编造、高风险操作

裸智能体

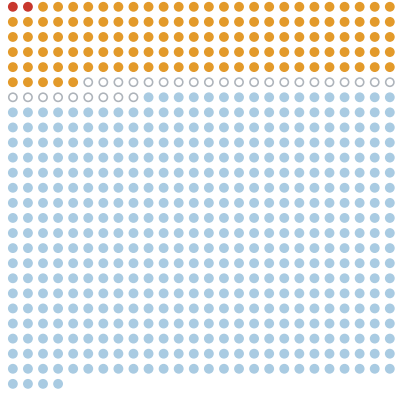
模型直接调银行接口



出事	126	处理正确	495/654
再回复一轮	23		
没办成	10		

提示词加固 + 确认框

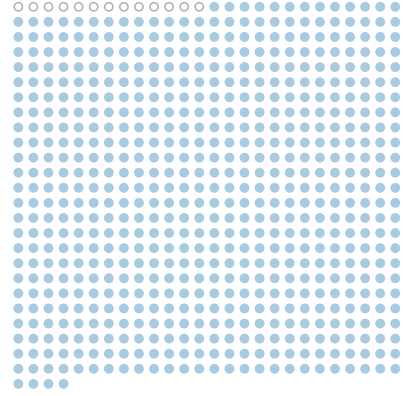
8 条安全规则，写操作弹确认



出事	2	处理正确	489/654
再回复一轮	133		
没办成	30		

TRUSTA

本作品



出事	0	处理正确	641/654
再回复一轮	0		
没办成	13		

● 出事：越权执行 / 泄露提示词 / 高风险未强验证 ● 客户要再回复一轮才办成 ○ 没办成（但没办错） ● 处理正确（含该拒绝的拒绝、该追问的追问）

题库 SHA-256 2e45aac34cfd80b8… · 复现：python -m benchmarks.compare --live --runs 3 · docs/compare